

La liste de candidats comme goulot : liage d'entités de santé sans entraînement

Olivier Caron

DRM, Université Paris-Dauphine, Université PSL, CNRS, 75016 Paris, France

olivier.caron@dauphine.psl.eu

RÉSUMÉ

Nous décrivons le système de l'équipe ACSS-PSL pour la tâche de liage d'entités du défi EvalLLM 2026 : relier chaque mention de santé pré-identifiée à un identifiant GeoNames (lieux) ou MeSH (pathogènes, maladies, toxines), ou la marquer comme hors-référentiel. Notre approche est frugale et sans entraînement. Une cascade de règles déterministes (normalisation, détection des cas hors-référentiel, génération de candidats par index local) est suivie d'un grand modèle de langue (LLM), appelé seulement sur les cas ambigus. Ce modèle choisit dans une liste fermée et ne génère jamais d'identifiant. Sur le jeu d'entraînement, le même score (RANKING 92,22) est obtenu que le modèle soit l'API GPT-5.4-nano ou un modèle ouvert local (gemma-4-31b, Qwen3.6-35B-A3B). Ce plateau partagé suggère que le goulot n'est pas le LLM mais la liste de candidats. L'empreinte carbone du run local est mesurée à environ 1,15 g équivalent CO₂.

ABSTRACT

The Candidate List as the Bottleneck: Training-Free Health Entity Linking

We describe the ACSS-PSL system for the entity linking task of the EvalLLM 2026 challenge : linking each pre-identified health mention to its identifier (GeoNames for places, MeSH for pathogens, diseases and toxins), or marking it as out-of-knowledge-base. Our approach is frugal and training-free. A deterministic cascade of rules (normalisation, out-of-base detection, candidate generation from local indexes) is followed by an LLM used only to disambiguate the remaining ambiguous cases. On the training set, the same score (RANKING 92.22) is reached whether the model is the GPT-5.4-nano API or an open model served locally (gemma-4-31b, Qwen3.6-35B-A3B), which suggests the bottleneck is the candidate list, not the LLM. The carbon footprint of the local run is measured at about 1.15 g CO₂-equivalent.

MOTS-CLÉS : liage d'entités, génération de candidats, GeoNames, MeSH, LLM, veille sanitaire.

KEYWORDS: entity linking, candidate generation, GeoNames, MeSH, LLM, health surveillance.

1 Introduction

La veille sanitaire repose en partie sur la lecture de textes en français (dépêches, rapports, articles) où il faut identifier des lieux et des agents de santé, puis les relier à des référentiels stables. Le défi EvalLLM 2026 propose cette tâche de *liage d'entités* : les mentions sont déjà repérées dans le texte, et il faut associer à chacune un identifiant dans GeoNames pour les lieux, ou dans MeSH pour les pathogènes, maladies et toxines, ou bien décider qu'aucune entrée du référentiel ne convient (cas hors-référentiel, ou NIL).

Le cadre est celui des très faibles ressources : le jeu d’entraînement ne contient que quelques dizaines de documents annotés. Entraîner un modèle génératif dans ces conditions exposerait à un fort risque de surapprentissage. Nous faisons donc le choix inverse, frugal : aucun modèle n’est entraîné. Le cœur du système est une cascade de règles déterministes qui s’appuie sur des index locaux (GeoNames, MeSH). Un grand modèle de langue (*Large Language Model*, LLM) n’intervient qu’en dernier recours, pour départager les seuls cas où plusieurs candidats subsistent.

Ce choix soulève une question simple : le LLM est-il le facteur limitant ? Nous montrons que non. En remplaçant le modèle de désambiguïsation par trois modèles très différents (une API propriétaire et deux modèles ouverts), nous obtenons le même score sur le jeu d’entraînement. Le goulot se situe ailleurs, dans la couverture de la liste de candidats. Plusieurs ablations l’étayaient (section 6). Par souci de transparence, nous soumettons une configuration enrichie de quelques règles issues du fichier de test et une configuration strictement généraliste, sans effet sur le score d’entraînement. L’empreinte carbone est mesurée pour le run local (Green Algorithms) et estimée pour l’API (EcoLogits). Le code est disponible publiquement¹.

2 Travaux connexes

2.1 Liage d’entités biomédicales

Le liage d’entités biomédicales s’appuie souvent sur un pré-entraînement coûteux, qu’il repose sur des représentations denses (BioSyn (Sung *et al.*, 2020), SapBERT (Liu *et al.*, 2021), KRISSBERT (Zhang *et al.*, 2022), ou les représentations de BioLORD-2023 (Remy *et al.*, 2023) dont le liage est l’une des tâches d’évaluation) ou sur la génération (GenBioEL (Yuan *et al.*, 2022)). L’évaluation comparative de Kartchner *et al.* (2023) décrit le cadre en deux étapes, une génération de candidats peu coûteuse suivie d’une désambiguïsation plus précise, et rappelle que les grands modèles génératifs hallucinent. Pour le français, les ressources biomédicales restent limitées, en particulier pour la normalisation d’entités : Wajsbürt *et al.* (2021) rapportent que moins de 4 % des concepts de l’UMLS disposent d’un terme français. Plus largement, les travaux récents sur le TAL biomédical français, tels que DrBERT (Labrak *et al.*, 2023) et CamemBERT-bio (Touchent *et al.*, 2023), illustrent que l’adaptation au domaine repose sur un pré-entraînement dédié, même lorsque l’évaluation porte sur d’autres tâches de TAL biomédical (reconnaissance d’entités, classification, questions-réponses) plutôt que sur le liage. Pour pallier cette rareté, xMEN (Borchert *et al.*, 2025) génère des candidats multilingues en exploitant les alias anglais quand ceux de la langue cible manquent.

2.2 Modèles de langue comme désambiguïsateurs contraints

Plusieurs travaux récents emploient un modèle de langue à l’étape de désambiguïsation d’un liage en deux temps, sans entraînement. Ye & Mitchell (2025) montrent qu’un modèle de langue utilisé comme désambiguïsateur sur des listes de candidats biomédicaux améliore nettement l’exactitude sans fine-tuning, et que la performance dépend fortement de la qualité de la génération de candidats. Pour empêcher le modèle de produire des identifiants invalides, Lin *et al.* (2025) contraignent son décodage au niveau des jetons aux entités valides de la base. Le cas où le bon candidat est absent

1. <https://github.com/oliviercaron/acss-psl-evalllm2026>.

de la liste est un problème reconnu du reranking : Zhou *et al.* (2024) montrent que supposer le bon candidat toujours présent ne tient pas en contexte zero-shot, et qu'un jugement explicite d'absence renseigne sur les limites de la génération de candidats.

LELA (Haffoudhi *et al.*, 2026) propose une chaîne sans entraînement qui génère des candidats puis laisse un modèle de langue choisir l'entité finale par son indice dans une liste fermée, avec un modèle à raisonnement et auto-cohérence. LELA cible la généralisation zero-shot sur des bancs d'essai anglophones variés (Wikipedia, acronymes, compétences professionnelles).

3 Tâche et données

Pour chaque mention pré-annotée (texte, type, position), il faut produire un identifiant et sa source : GeoNames pour les lieux (type LOCATION), MeSH pour les pathogènes, maladies et toxines, ou une absence d'identifiant pour les cas hors-référentiel. Le jeu d'entraînement compte 40 documents et 491 entités annotées (dont 470 avec identifiant de référence et 21 hors-référentiel), et le jeu de test 200 documents et 1840 entités sans référence fournie aux participants. Le guide d'alignement fourni par l'organisation précise les conventions de liage, et nous nous y conformons. Le classement officiel, que nous notons RANKING, est la moyenne de deux métriques fournies par l'organisation : l'exactitude InKB partielle (crédit partiel sur les concepts quand les descripteurs principaux sont corrects), qui évalue la désambiguïsation sur les seules mentions liables (NIL exclus), et la F-mesure de liage (*NEL FI*), qui évalue le système complet (NIL compris). Nous rapportons les scores officiels sur le test (section 6). Les analyses fines de réglage et d'erreurs s'appuient sur le jeu d'entraînement, faute d'annotation de référence sur le test.

La difficulté de liage n'est pas la même selon le référentiel. La figure 1 montre, pour les 470 entités à lier du corpus (hors 21 NIL), le nombre de candidats que l'index retrouve avant désambiguïsation. Côté MeSH, le dictionnaire résout presque toujours la mention à un seul concept, si bien que le LLM n'est quasiment jamais sollicité. Côté GeoNames, au contraire, la majorité des lieux donne lieu à plusieurs candidats homonymes (2 à 5, 6 à 20, voire plus de 20), ce qui rend la désambiguïsation indispensable. C'est donc sur les lieux que se concentre le travail du LLM.




FIGURE 1 – Profil d'ambiguïté par référentiel sur le corpus d'entraînement : distribution des 470 entités à lier (les 21 NIL exclues) selon le nombre de candidats retrouvés par l'index avant désambiguïsation.

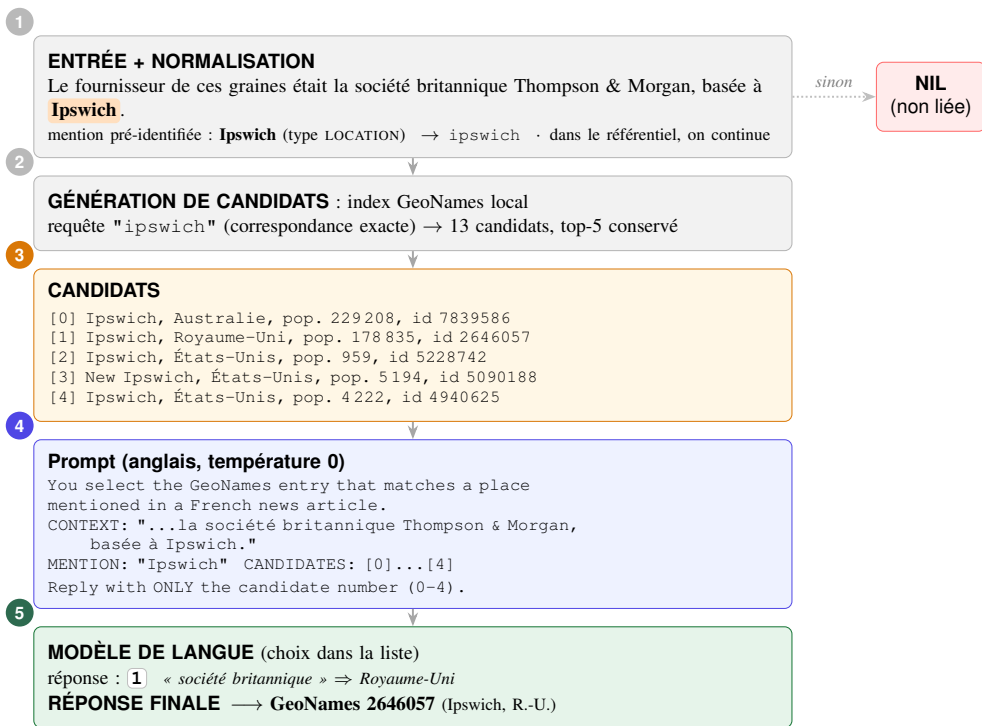


FIGURE 2 – Exemple réel de liage tiré du corpus d’entraînement (enquête sur une épidémie à E. coli liée à des graines de fenugrec). La mention « Ipswich », ambiguë entre treize homonymes, est résolue vers le Royaume-Uni grâce à l’indice contextuel « société britannique ». Tous les candidats, identifiants et populations sont ceux réellement produits par le programme.

4 Système

Le système traite chaque mention par une cascade déterministe. Le LLM n’intervient qu’à la fin, et seulement si plusieurs candidats subsistent (figure 2).

La cascade commence par normaliser la mention : passage en minuscules, nettoyage typographique, variantes sans accents, et translittération du grec en dernier recours. Un filtre de motifs lexicaux marque ensuite comme non liées les mentions manifestement absentes du référentiel (quartiers, zones, bassins, ceintures, venins bruts). Les concepts géographiques nus sont traités avec prudence : lorsqu’une périphrase référentielle est reconnue (par exemple « continent africain » ou « territoire américain »), elle est redirigée vers un pays ou un continent par une règle dédiée, sinon la mention peut rester non liée selon le guide d’alignement.

Le traitement diverge ensuite selon le référentiel. Pour les lieux, une première couche de règles générales (validées sur le guide et le jeu d’entraînement) redirige certaines mentions vers leur entité géographique : « Hexagone » vers « France », une périphrase « territoire » suivie d’un gentilé vers le pays, ou les sous-régions des Nations unies. Un index SQLite de GeoNames génère ensuite les candidats, par plusieurs passes de correspondance sur les noms, les noms francisés et les codes

de type de lieu de GeoNames. Un post-traitement géographique tranche : préférence au pays, à la capitale ou au chef-lieu, réconciliation des codes par les coordonnées, et garde-fous contre les rues et bâtiments. Pour les concepts biomédicaux, un dictionnaire français curé associe les termes courants à leur descripteur MeSH, et des règles propres aux étiquettes séparent le pathogène de la maladie (par exemple le virus du VIH et le SIDA). En cas d'échec, un index MeSH bilingue est interrogé. S'y ajoutent une règle « souche » (par exemple *E. coli* O104) et une règle qui propage, dans tout le document, le lien d'un acronyme vers sa forme développée.

Quand au moins deux candidats subsistent après ces étapes, un LLM choisit dans la liste complète des candidats (*listwise reranking*). C'est le seul appel au LLM, et il est volontairement contraint. À température 0, le modèle reçoit deux choses : un extrait local de ± 200 caractères autour de la mention (borné à 500 caractères dans le prompt) et une liste numérotée de candidats. Il répond par un seul indice, et l'identifiant final est lu dans la liste. Le modèle ne génère jamais d'identifiant, ce qui rend les erreurs analysables comme un défaut de génération de candidats ou de choix dans la liste. Nous limitons la liste à cinq candidats pour les lieux (réglage justifié en section 6) et à dix pour les concepts, sans effet observé côté MeSH où l'index ne renvoie quasiment jamais plus d'un candidat. Un extrait du prompt figure en annexe A et les hyperparamètres complets en annexe B. Chaque règle ajoutée est verrouillée par des tests de non-régression (104 tests : détection NIL, périphrases, translittération du grec, règle de souche, garde-fous contre les rues et bâtiments, validateur de format de soumission), de sorte qu'un ajout n'invalide pas un cas déjà résolu.

5 Configuration expérimentale

Les trois runs varient selon deux axes : le modèle de désambiguïsation et la présence de deux ressources additionnelles (règles issues de l'examen du fichier de test, exonymes français tirés de Wikidata). Le cache Wikidata n'est pas un référentiel de sortie : il contient seulement, pour quelques lieux restés NIL après la cascade GeoNames, des identifiants GeoNames récupérés hors ligne via la propriété Wikidata P1566. À la prédiction, aucun accès réseau n'est effectué. Ces identifiants sont rechargés depuis la base GeoNames locale, filtrés puis désambiguïsés comme les autres candidats. Cette configuration généraliste (run 2) est dérivée du run 3 sans relancer le LLM : les ajouts issus de l'examen du test (cache d'exonymes Wikidata vers GeoNames, clusters Marburg, encéphalite à tiques, VHC) sont ramenées à NIL par une règle déterministe (tableau 1). Pour l'étape de désambiguïsation, nous comparons l'API GPT-5.4-nano (température 0) à des modèles ouverts servis localement avec vLLM (Kwon *et al.*, 2023) sur un GPU NVIDIA H100 : gemma-4-31b (31 milliards de paramètres) et Qwen3.6-35B-A3B (un modèle à mélange d'experts, raisonnement désactivé), ainsi que la famille Qwen2.5 (7, 32 et 72 milliards) à titre de comparaison. Toutes les évaluations sur le jeu d'entraînement sont conduites sans la mémoire d'entraînement (option `no-memory`), de sorte que le score mesure la cascade de règles et le modèle de langue, et non un rappel direct des annotations déjà vues. L'énergie du GPU local est mesurée directement par échantillonnage de la puissance (nvidia-smi à 1 Hz), puis convertie selon la méthode Green Algorithms (Lannelongue *et al.*, 2021). Pour les appels d'API, dont le matériel n'est pas observable, l'empreinte est estimée avec EcoLogits (GenAI Impact, 2024).

Plusieurs alternatives plus lourdes ont été testées sur le jeu d'entraînement puis écartées faute de gain. Sur la configuration à dix candidats, un prompt rédigé entièrement en français dégrade le RANKING de 91,19 à 90,12, une perte portée uniquement par GeoNames (F1 89,84 contre 88,20), MeSH restant inchangé car ses candidats sont présentés de façon bilingue. Ce résultat rejoint les

Run	Modèle (étape 5)	Couverture	Liées / NIL
run 1	gemma-4-31b (local)	étendue	1700 / 140
run 2	GPT-5.4-nano (API)	généraliste	1654 / 186
run 3	GPT-5.4-nano (API)	étendue	1700 / 140

TABLE 1 – Les trois runs soumis (jeu de test, 1840 mentions). La couverture « étendue » ajoute quelques termes spécialisés et un cache d’exonymes Wikidata vers GeoNames. La version généraliste retire ces ajouts par retour déterministe vers NIL, ce qui explique les 46 mentions de différence.

travaux montrant que les instructions anglaises surpassent souvent leur traduction pour les modèles *English-centric* (Lai *et al.*, 2023), un effet cohérent avec l’existence d’un espace conceptuel interne biaisé vers l’anglais (Wendler *et al.*, 2024). Le liage d’entités y reste d’ailleurs peu exploré (Zaghir *et al.*, 2024). Le vote majoritaire sur gemma n’apporte pas de gain. Le réglage de la taille de liste est traité au tableau 5.

6 Résultats

6.1 Le LLM n’est pas le facteur limitant

Le tableau 2 donne le score d’entraînement pour chaque modèle de désambiguïsation. Trois modèles très différents atteignent exactement le même RANKING de 92,22, avec les mêmes F-mesures par référentiel (GeoNames et MeSH). Passer de 32 à 72 milliards de paramètres au sein de la famille Qwen2.5 ne modifie pas le score (91,59). Dans les configurations testées sur le jeu d’entraînement, le score ne dépend donc ni du modèle ni de sa taille au-delà d’un seuil, et la F-mesure MeSH est identique pour tous, les listes de candidats MeSH étant courtes. Côté GeoNames, le LLM est pourtant sollicité sur 240 des 305 mentions (celles à au moins deux candidats), et les trois modèles y atteignent la même F-mesure (91,06). Le fait que le choix du modèle ne modifie pas le score sur la portion où il est le plus sollicité rejoint la section 6.3 : le résiduel d’erreurs tient à la génération de candidats (référence absente de la liste ou mauvais niveau administratif), un problème qui s’impose à tout reranker.

Modèle (étape 5)	RANKING	InKB part.	NEL F1	F1 GeoNames	F1 MeSH
GPT-5.4-nano (API)	92,22	92,12	92,32	91,06	94,74
gemma-4-31b (local)	92,22	92,13	92,32	91,06	94,74
Qwen3.6-35B-A3B (local)	92,22	92,13	92,32	91,06	94,74
Qwen2.5-72B (local)	91,59	91,49	91,68	90,08	94,74
Qwen2.5-32B (local)	91,59	91,49	91,68	90,08	94,74
Qwen2.5-7B (local)	87,33	87,23	87,42	83,58	94,74

TABLE 2 – Score d’entraînement selon le modèle de désambiguïsation. Le RANKING est la moyenne de l’exactitude partielle InKB et de la F-mesure de liage (NEL F1). Les valeurs affichées sont arrondies à deux décimales, le RANKING étant calculé sur les valeurs non arrondies (d’où 92,22 malgré des InKB partielles de 92,12 et 92,13).

6.2 Réglages de la désambiguïsation

Nous avons isolé l’effet du nombre de candidats GeoNames en fixant le contexte à ± 200 caractères et en ne faisant varier que la taille de la liste (tableau 5 en annexe, deux exécutions par configuration). La liste courte est la plus efficace, et de façon stable : le top-5 atteint 92,22 sur ses deux tirages (variance nulle), au-dessus de toute la bande de variance des listes plus longues, qui forment un plateau bruité de dix à vingt candidats (91,8 à 91,9). Donner à la fois davantage de contexte (± 600) et davantage de candidats (top-30) n’apporte pas de gain (91,21 contre 91,42). Toutefois, ce test fait varier deux facteurs à la fois, il ne prouve donc pas l’optimalité de 200 caractères, mais il montre que l’ajout naïf d’information ne résout pas les cas difficiles. Avec deux tirages par configuration, ces écarts sont un indice, non une preuve statistique.

6.3 Le goulot est souvent la liste de candidats

Nous avons inspecté les erreurs au moyen d’un visualiseur HTML autonome qui affiche, pour chaque erreur, le document avec la mention surlignée, le lien attendu et le lien prédit. Pour les lieux, il ajoute la liste des candidats GeoNames réellement générés avec le rang de la référence (annexe E). Cette inspection montre que beaucoup d’erreurs GeoNames ne sont pas des erreurs de choix mais de génération de candidats. Sur les vingt-quatre erreurs d’identifiant GeoNames examinées, le bon identifiant est absent de la liste dans six cas (par exemple « Caucase » ou « commune IV de Bamako ») et placé au-delà du rang retenu dans deux autres (« Sedan » au rang 37). Dans ces situations, aucun reranker, même plus grand, ne peut sélectionner un candidat qui n’a pas été produit. Les seize erreurs restantes sont des confusions de niveau administratif, comme « Cannes » ou « Bègles » liés à la commune plutôt qu’à la localité, ou « Amesbury », dont les métadonnées sont pauvres. Elles relèvent du choix du bon code de *feature* et du post-traitement géographique, pas du reranking sémantique.

6.4 Résultats officiels sur le test

Les scores officiels communiqués par l’organisation prolongent l’analyse tirée du jeu d’entraînement. Sur les 19 soumissions des 7 équipes participantes, nos trois configurations se situent nettement au-dessus de la médiane (tableau 3). Notre meilleure soumission (run 1, gemma-4-31b en local) atteint un RANKING de 84,52, soit plus de dix points au-dessus de la médiane (74,46). La configuration strictement généraliste (run 2), dépourvue de toute règle issue de l’examen du test, reste à 82,25, là encore très au-dessus de la médiane.

Soumission	Configuration	InKB part.	NEL F1	RANKING
run 1	gemma-4-31b local, étendue	83,36	85,67	84,52
run 3	GPT-5.4-nano API, étendue	82,97	85,27	84,12
run 2	GPT-5.4-nano API, généraliste	80,58	83,92	82,25
médiane	19 soumissions	73,73	75,18	74,46

TABLE 3 – Scores officiels sur le jeu de test (1840 mentions). Le RANKING est la moyenne de l’exactitude partielle InKB et de la F-mesure de liage, les deux composantes communiquées par l’organisation. La médiane porte sur l’ensemble des soumissions du défi.

Le modèle local (run 1) et l’API propriétaire (run 3) restent à moins d’un demi-point l’un de l’autre sur le score global (0,40 de RANKING). Sur le jeu d’entraînement, trois modèles très différents obtenaient déjà le même score (92,22). Les résultats de test restent donc compatibles avec notre interprétation : remplacer un modèle local de 31 milliards de paramètres par une API propriétaire déplace le score global de moins d’un demi-point. Nous restons prudents, car le modèle Qwen3.6-35B-A3B n’a pas été soumis sur le test et la couverture réelle de la liste de candidats n’y est pas vérifiable sans annotation de référence.

L’écart entre la configuration étendue et la configuration généraliste atteint en revanche 1,87 point de RANKING sur le test, à modèle identique (run 3 contre run 2), alors qu’il était nul sur le jeu d’entraînement. Ce contraste est cohérent avec notre démarche : les quelques règles issues de l’examen du test ciblent des entités présentes dans le fichier de test mais absentes du jeu d’entraînement, si bien qu’elles ne modifient pas le score d’entraînement et n’apportent un gain que sur le test. Ce gain porte surtout sur MeSH, où l’ajout de termes spécialisés fait passer la F-mesure de 76,42 à 79,34.

6.5 Le dictionnaire MeSH généralise moins bien que l’index GeoNames

La comparaison entraînement/test, décomposée en précision et rappel par référentiel, révèle un comportement très différent des deux ressources (tableau 4). GeoNames ne perd que deux points de F-mesure entre l’entraînement et le test, tandis que MeSH en perd quinze. Cette baisse est portée avant tout par le rappel, qui diminue fortement, de près de dix-neuf points côté MeSH contre trois côté GeoNames.

Référentiel	Mesure	Train	Test	Δ
GeoNames	Précision	90,32	89,36	−0,96
	Rappel	91,80	88,73	−3,07
	F1	91,06	89,04	−2,02
MeSH	Précision	96,84	85,61	−11,23
	Rappel	92,73	73,93	−18,80
	F1	94,74	79,34	−15,40

TABLE 4 – Précision, rappel et F-mesure par référentiel, sur le jeu d’entraînement (éval interne) et sur le test (run 1). La chute MeSH est portée par le rappel.

Une part importante des concepts MeSH du test n’est vraisemblablement retrouvée ni par notre dictionnaire français ni par l’index bilingue. Ces mentions restent non liées, ce qui explique la baisse du rappel. L’index GeoNames, qui compte près de 13,4 millions de lieux et 28 millions de noms, couvre au contraire les lieux du test presque aussi bien que ceux du jeu d’entraînement. Le score MeSH du jeu d’entraînement (94,74) doit en outre être interprété comme une borne optimiste, le dictionnaire ayant été élaboré manuellement en observant le jeu d’entraînement. Une ressource construite à la main surajuste le vocabulaire observé, tandis qu’un index plus large généralise mieux. Sur les 165 mentions MeSH liées du jeu d’entraînement, le dictionnaire et l’index bilingue renvoient un seul candidat dans 158 cas et aucun dans 7. Le modèle de langue n’est donc sollicité que sur une poignée de mentions volontairement marquées comme ambiguës (« cancers », « E. coli »). Cet appel ne déplace pas la F-mesure MeSH, identique pour les six modèles : pour les « cancers » composites, la métrique mono-identifiant n’accorde aucun crédit quel que soit l’identifiant retenu, et les souches d’E. coli sont départagées en amont par une règle déterministe.

7 Empreinte carbone

Nous séparons deux cas selon le matériel. Le run local utilise un matériel connu : gemma-4-31b sur GPU NVIDIA H100 en France, et la cascade de règles sur un processeur AMD Ryzen 5 5600X. L'énergie du GPU est mesurée (11,2 Wh), puis convertie avec Green Algorithms (France 56 g/kWh, PUE serveur 1,67²), ce qui donne environ 1,05 g. La cascade sur le processeur ajoute environ 0,10 g, pour un total d'environ 1,15 g. Pour les runs via API, le matériel d'OpenAI n'étant pas observable, nous estimons l'empreinte avec EcoLogits, soit environ 1,8 à 4,0 g par run. Le détail par soumission figure en annexe D (tableau 6).

L'approche reste sobre dans tous les cas, le LLM n'étant appelé que sur les cas ambigus. Le total des trois soumissions se situe autour de 4,8 à 9 g CO₂eq.

8 Discussion

Nos résultats dessinent une même lecture : le modèle de langue fonctionne mieux comme arbitre d'une liste courte et pré-filtrée que comme explorateur d'une liste large et bruitée, et les gains résiduels relèvent de la génération de candidats, ce que confirme la chute de rappel MeSH entre l'entraînement et le test. Ce constat conforte le choix frugal : un modèle ouvert servi en local atteint la même qualité qu'une API propriétaire, sans dépendance externe ni coût carbone élevé, le LLM y jouant un rôle d'appoint plutôt que de pièce maîtresse.

9 Limites

Notre système hérite des limites de sa cascade. Cette cascade renvoie le plus souvent un identifiant unique par mention, alors que certaines annotations sont composites. Sur le jeu d'entraînement, 14 des 165 mentions MeSH liées (8,5 %) portent au moins deux identifiants (deux descripteurs, ou un descripteur et un concept supplémentaire), contre aucune côté GeoNames. Pour les annotations à deux descripteurs, une sortie mono-descripteur ne reçoit aucun crédit. Les autres erreurs tiennent surtout à un défaut de couverture, notamment des toxines absentes du dictionnaire. Une sortie multi-identifiants ne corrigerait donc qu'une partie de ces cas. Cette proportion n'est mesurable que sur le jeu d'entraînement, l'annotation de référence du test n'étant pas communiquée. Les ressources et règles sont par ailleurs calibrées sur le français et la veille sanitaire, et leur portée à d'autres langues ou domaines n'est pas évaluée.

Le reranker conserve une variance faible mais non nulle, même à température 0. Sur quatre exécutions identiques sur le jeu d'entraînement avec une configuration à dix candidats, le RANKING varie de 91,4 à 92,0 et des homonymes comme « Sedan » ou « Fukushima » changent d'identifiant d'un tirage à l'autre. Les comparaisons fines entre configurations doivent donc être interprétées à cette échelle. Notre test à contexte élargi ne constitue pas un balayage exhaustif des fenêtres de contexte.

Nous signalons explicitement la configuration ajustée après examen du test (run 1 et run 3) : elle repose sur des règles définies après lecture des entrées du fichier de test (qui ne contient pas d'annotation de

2. *Power Usage Effectiveness* : rapport entre l'énergie totale du centre de calcul et celle consommée par le seul matériel informatique.

référence). Ces règles incluent des variantes MeSH spécialisées et un cache figé d'exonymes Wikidata vers GeoNames, qui produit 14 liens supplémentaires dans la couverture étendue. Nous fournissons par ailleurs une configuration strictement généraliste (run 2) pour permettre une comparaison équitable.

10 Conclusion

Nous avons présenté un système de liage d'entités de santé frugal et sans entraînement, fondé sur une cascade de règles déterministes et un LLM appelé seulement sur les cas ambigus. Sur le jeu d'entraînement, le score plafonne identiquement quel que soit le modèle : le LLM n'est pas le facteur limitant, la liste de candidats l'est. L'empreinte carbone est faible et, pour le run local, mesurée. Les pistes naturelles d'amélioration portent sur la couverture de la recherche de candidats (ressources et normalisation), plutôt que sur la taille du modèle.

Références

- BORCHERT F., LLORCA I., ROLLER R., ARNRICH B. & SCHAPRANOW M.-P. (2025). xMEN : a modular toolkit for cross-lingual medical entity normalization. *JAMIA Open*, **8**(1), ooa147. DOI : [10.1093/jamiaopen/ooae147](https://doi.org/10.1093/jamiaopen/ooae147).
- GENAI IMPACT (2024). EcoLogits : Estimating the environmental impacts of generative AI. <https://ecologits.ai>. Bibliothèque logicielle.
- HAFFOUDHI S., SUCHANEK F. M. & HOLZENBERGER N. (2026). LELA : an LLM-based entity linking approach with zero-shot domain adaptation. arXiv :2601.05192. DOI : [10.48550/arXiv.2601.05192](https://doi.org/10.48550/arXiv.2601.05192).
- KARTCHNER D., DENG J., LOHIYA S., KOPPARTHI T., BATHALA P., DOMINGO-FERNÁNDEZ D. & MITCHELL C. (2023). A comprehensive evaluation of biomedical entity linking models. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)* : Association for Computational Linguistics. DOI : [10.18653/v1/2023.emnlp-main.893](https://doi.org/10.18653/v1/2023.emnlp-main.893).
- KWON W., LI Z., ZHUANG S., SHENG Y., ZHENG L., YU C. H., GONZALEZ J. E., ZHANG H. & STOICA I. (2023). Efficient memory management for large language model serving with PagedAttention. In *Proceedings of the 29th Symposium on Operating Systems Principles (SOSP)*. DOI : [10.1145/3600006.3613165](https://doi.org/10.1145/3600006.3613165).
- LABRAK Y., BAZOGE A., DUFOUR R., ROUVIER M., MORIN E., DAILLE B. & GOURRAUD P.-A. (2023). DrBERT : A robust pre-trained model in French for biomedical and clinical domains. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL)* : Association for Computational Linguistics. DOI : [10.18653/v1/2023.acl-long.896](https://doi.org/10.18653/v1/2023.acl-long.896).
- LAI V. D., NGO N. T., VEYSEH A. P. B., MAN H., DERNONCOURT F., BUI T. & NGUYEN T. H. (2023). ChatGPT beyond English : Towards a comprehensive evaluation of large language models in multilingual learning. In *Findings of the Association for Computational Linguistics : EMNLP 2023* : Association for Computational Linguistics. DOI : [10.18653/v1/2023.findings-emnlp.878](https://doi.org/10.18653/v1/2023.findings-emnlp.878).
- LANNELONGUE L., GREALEY J. & INOUE M. (2021). Green algorithms : Quantifying the carbon footprint of computation. *Advanced Science*, **8**(12), 2100707. DOI : [10.1002/adv.202100707](https://doi.org/10.1002/adv.202100707).
- LIN Z., ZHANG Z., WU J., ZHENG Y. & WU X. (2025). Guiding large language models for biomedical entity linking via restrictive and contrastive decoding. In *Findings of the Association*

for Computational Linguistics : EMNLP 2025 : Association for Computational Linguistics. DOI : [10.18653/v1/2025.findings-emnlp.1292](https://doi.org/10.18653/v1/2025.findings-emnlp.1292).

LIU F., SHAREGHI E., MENG Z., BASALDELLA M. & COLLIER N. (2021). Self-alignment pretraining for biomedical entity representations. In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies (NAACL-HLT)* : Association for Computational Linguistics. DOI : [10.18653/v1/2021.naacl-main.334](https://doi.org/10.18653/v1/2021.naacl-main.334).

REMY F., DEMUYNCK K. & DEMEESTER T. (2023). BioLORD-2023 : Semantic textual representations fusing LLM and clinical knowledge graph insights. arXiv :2311.16075. DOI : [10.48550/arXiv.2311.16075](https://doi.org/10.48550/arXiv.2311.16075).

SUNG M., JEON H., LEE J. & KANG J. (2020). Biomedical entity representations with synonym marginalization. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)* : Association for Computational Linguistics. DOI : [10.18653/v1/2020.acl-main.335](https://doi.org/10.18653/v1/2020.acl-main.335).

TOUCHENT R., ROMARY L. & DE LA CLERGERIE É. V. (2023). CamemBERT-bio : Leveraging continual pre-training for cost-effective models on French biomedical data. arXiv :2306.15550. DOI : [10.48550/arXiv.2306.15550](https://doi.org/10.48550/arXiv.2306.15550).

WAJSBÜRT P., SARFATI A. & TANNIER X. (2021). Medical concept normalization in French using multilingual terminologies and contextual embeddings. *Journal of Biomedical Informatics*, **114**, 103684. DOI : [10.1016/j.jbi.2021.103684](https://doi.org/10.1016/j.jbi.2021.103684).

WENDLER C., VESELOVSKY V., MONEA G. & WEST R. (2024). Do llamas work in English ? on the latent language of multilingual transformers. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL)* : Association for Computational Linguistics. DOI : [10.18653/v1/2024.acl-long.820](https://doi.org/10.18653/v1/2024.acl-long.820).

YE C. & MITCHELL C. S. (2025). LLM as entity disambiguator for biomedical entity-linking. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 2 : Short Papers)* : Association for Computational Linguistics. DOI : [10.18653/v1/2025.acl-short.25](https://doi.org/10.18653/v1/2025.acl-short.25).

YUAN H., YUAN Z. & YU S. (2022). Generative biomedical entity linking via knowledge base-guided pre-training and synonyms-aware fine-tuning. In *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies (NAACL-HLT)* : Association for Computational Linguistics. DOI : [10.18653/v1/2022.naacl-main.296](https://doi.org/10.18653/v1/2022.naacl-main.296).

ZAGHIR J., NAGUIB M., BJELOGRLIC M., NÉVÉOL A., TANNIER X. & LOVIS C. (2024). Prompt engineering paradigms for medical applications : Scoping review. *Journal of Medical Internet Research*, **26**, e60501. DOI : [10.2196/60501](https://doi.org/10.2196/60501).

ZHANG S., CHENG H., VASHISHTH S., WONG C., XIAO J., LIU X., NAUMANN T., GAO J. & POON H. (2022). Knowledge-rich self-supervision for biomedical entity linking. In *Findings of the Association for Computational Linguistics : EMNLP 2022* : Association for Computational Linguistics. DOI : [10.18653/v1/2022.findings-emnlp.61](https://doi.org/10.18653/v1/2022.findings-emnlp.61).

ZHOU K., LI Y., WANG Q., QIAO Q. & LI Q. (2024). GenDecider : Integrating “none of the candidates” judgments in zero-shot entity linking re-ranking. In *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies (Volume 2 : Short Papers)* : Association for Computational Linguistics. DOI : [10.18653/v1/2024.naacl-short.22](https://doi.org/10.18653/v1/2024.naacl-short.22).

A Extrait du prompt de désambiguïsation

Le modèle reçoit le contexte de la mention et une liste numérotée de candidats, puis renvoie un seul numéro. Le prompt est rédigé en anglais. Pour les lieux, sa structure est la suivante (le prompt MeSH est analogue).

```
You select the GeoNames entry that matches a place mentioned in
a French news article.

CONTEXT: "{context}"
MENTION: "{mention}"
CANDIDATES: {numbered list}

How to choose:
- Identify the country/region from the context.
- The right candidate must match that country/region.
- Population is only a tiebreaker among matching candidates.

Reply with ONLY the candidate number (0-N).
```

Le prompt complet et sa variante française figurent dans le code (fonctions `_build_rerank_prompt` et `_build_rerank_prompt_fr` pour les lieux, `_build_mesh_rerank_prompt` pour les concepts).

B Hyperparamètres

Modèle de langue : température 0, au plus 100 tokens de sortie, au plus 5 candidats pour GeoNames et 10 pour MeSH. Le contexte est extrait avec une fenêtre locale de ± 200 caractères autour de la mention, puis borné à 500 caractères dans le prompt (paramètre `context_chars`). Configuration de soumission : `-no-memory -llm-reranker`, le modèle répond uniquement par un indice et le délai d'attente est fixé à 60 s par requête. Modèles locaux servis avec vLLM 0.22 (Python 3.12) sur un GPU H100, poids quantisés en FP8, via une interface locale compatible OpenAI (`LLM_BASE_URL`, `LLM_MODEL`). API distante : GPT-5.4-nano à température 0. Référentiels interrogés par index local : GeoNames et MeSH (traduction française Inserm). Estimation carbone : Green Algorithms pour le matériel local, EcoLogits 0.10 pour l'API. Le code, les versions exactes des paquets et les empreintes des index sont fournis dans le dépôt.

C Réglage du reranking par liste

Réglage de l'étape 5	RANKING	F1 GeoNames	Lecture
top-10, ± 200 (version antérieure)	91,42	89,90	ancres avant balayage
top-30, ± 600	91,21	89,58	pas de gain
top-5, ± 200	92,22	91,06	meilleur, retenu
top-10, ± 200	91,90	90,57	moins stable
top-15, ± 200	91,80	90,41	pas mieux
top-20, ± 200	91,90	90,57	pas mieux

TABLE 5 – Réglages de la désambiguïsation par liste sur le jeu d’entraînement. Les deux premières lignes sont des configurations antérieures (top-10 et test à contexte élargi, ce dernier avec `context_chars` porté à 1300). Les quatre dernières sont un balayage propre du nombre de candidats GeoNames, à contexte fixé à ± 200 caractères, moyenné sur deux exécutions. La taille de liste ne concerne que GeoNames, les listes MeSH étant trop courtes pour être tronquées.

D Détail de l’empreinte carbone

Soumission	Énergie LLM	gCO ₂ eq	Méthode
run 1 (gemma local)	11,2 Wh (mesuré)	$\approx 1,15$	Green Alg.
run 2 (nano API)	3 à 8 Wh (estimé)	1,8 à 4,0	EcoLogits
run 3 (nano API)	3 à 8 Wh (estimé)	1,8 à 4,0	EcoLogits
Total (3 runs)		4,8 à 9,0	

TABLE 6 – Énergie d’inférence du modèle de langue et empreinte carbone par soumission. L’énergie du run 1 est mesurée au GPU (`nvidia-smi`). Celle des runs API est estimée par EcoLogits. L’empreinte inclut la cascade de règles sur le processeur du poste fixe. L’énergie d’inférence du nano est plus basse que celle de gemma, mais son empreinte estimée est plus élevée, car EcoLogits suppose une grille mondiale moyenne et inclut la fabrication du matériel, là où le run local bénéficie de la grille française décarbonée.

Détail de la mesure du run 1 : 779 appels au modèle sur l’ensemble du jeu de test, près de 300 000 tokens d’entrée, 167 s à 242 W en moyenne (intégration `nvidia-smi` à 1 Hz). Le processeur du poste fixe, hors centre de données, est compté avec un PUE de 1 et ajoute environ 0,10 g, l’essentiel des 1,15 g venant du GPU.

E Analyse d’erreurs

Le visualiseur d’erreurs décrit en section 6.3 distingue directement les deux grandes familles d’erreurs. Côté GeoNames, la référence figure bien dans la liste mais la désambiguïsation se trompe (figure 3). Côté MeSH, une mention pourtant fiable reste hors-référentiel faute de candidat généré (figure 4).

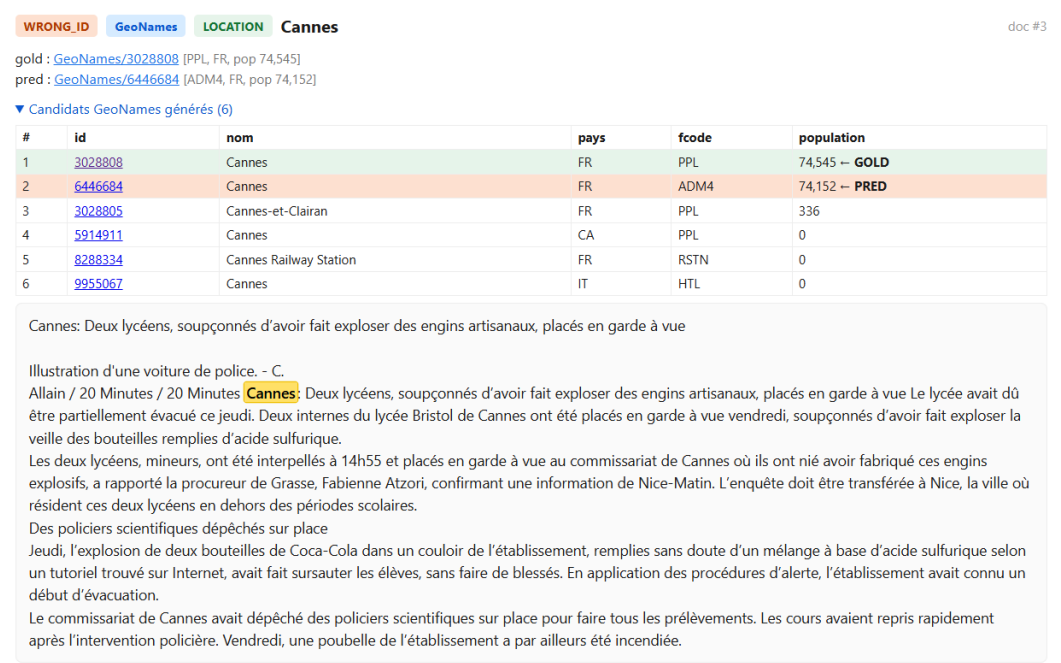


FIGURE 3 – Capture d’écran du visualiseur d’erreurs (cas « Cannes », doc #3). La référence (Cannes PPL, id 3028808) figure dans la liste de candidats *au rang 1*, mais le post-traitement géographique a retenu la commune (ADM4, id 6446684) à la place de la localité.

gold : MeSH/D039661

pred : NIL

Sciences & Innovations

Environnement

Aberkane : ces venins qui valent trente mille fois plus que l'or

Les neurotechnologies ont besoin des peptides contenus dans les venins et que nous ne savons pas encore synthétiser. Mais ils ont bien plus à nous apprendre.

Par Idriss J. Aberkane

Publié le 26/10/2014 à 12h03

La toxine APETx2 d'Anthopleura elegantissima se négocie à 600 euros le milligramme.

Si un jour vous entendez un de ces pseudo-docteurs en écologie industrielle ou un de ces Nobel d'économie du café des sports disserter sur l'intérêt de bétonner la barrière de corail ou d'industrialiser la forêt primaire pour mettre au travail ces paresseux de natifs, parlez-lui de la tarentule chinoise ou du cône du Pacifique. À côté de ce petit mollusque ultra-venimeux, la poule aux oeufs d'or fait figure de plaisanterie. La mu-conotoxine GIIIB se négocie à presque 500 euros le milligramme chez Alomone Labs. La variante PIIIA est, elle, à 800 euros le milligramme chez Smartox Biotech... 800 millions d'euros le kilo ! Le platine et l'héroïne pure ? Du terreau de jardin en comparaison.

La newsletter sciences et tech

FIGURE 4 – Capture d'écran du visualiseur d'erreurs (cas « PIIIA », doc #23). La toxine « PIIIA » (une conotoxine, type BIO_TOXIN) a pour référence MeSH D039661, mais l'index ne lui associe aucun candidat : le système la laisse hors-référentiel (NIL) au lieu de la lier.